

两版本对比实验报告

v0-initial (7d2e816) vs HEAD (2312ee9)

模型 DeepSeek deepseek-chat · agent agno · n=20 · seed=42 · 2026-08-28

摘要

codex 的改进没有改变 agent 行为（实验层零回归），但彻底重构了评测层：15 个不可复现的 LLM 打分指标替换为 15 个确定性 CODE 指标（保留 4 个 LLM），并新增 SQLite 审计 ledger。实测：评测耗时降低 2.3 - 2.6 倍，LLM 调用减少 71% - 73%，结果 100% 可复现，确定性 tool_recall 与旧版 LLM 打分完全吻合（0.410 = 0.410）。

2.6×

评测加速

耗时 6 - 7min → 2 - 3min

-73%

LLM API 调用

每实验 280 - 300 → 80 次

100%

结果可复现

CODE 指标 300/300 一致

零回归

实验层

mmlu token 逐字节一致

报告结构：1. L1 实验层回归 · 2. L2 评测层指标构成与语义变化 · 3. L3 成本与确定性 · 4. 结论 · 5. 发现并修复的仓库问题。完整方案与数据见 docs/perf-compare-v0-initial-vs-head.md 与 docs/perf-compare-results.md。

1 L1 实验层回归：无回归

用同一套（新版）评测管线评两版实验。mmlu 两版实验的 token 用量逐字节一致（246.65），turn / tool 指标全部一致，证明采样与 prompt 完全相同，实验层零回归。tau 的 correctness 差异（0.35 vs 0.55）是多轮对话模型输出随机性导致的轨迹分叉，并非代码回归——两版 task 层代码相同（git diff 为空）已直接证明。




图 1 · 同一评测管线评两版实验的 correctness 平均分

共有确定性指标对比

指标	new-exp mmlu	old-exp mmlu	new-exp tau	old-exp tau
correctness	0.900	0.850	0.350	0.550
task_succeeded	1.000	1.000	1.000	1.000
turn_count	1.000	1.000	4.150	4.600
total_token_usage	246.65	246.65	23424.7	25960.4
tool_call_count	0.000	0.000	5.400	6.050

2 L2 评测层：指标构成与语义变化

LLM 指标从 15 个降到 4 个 (-73%)，新增 6 个确定性指标：plan_structure、response_compactness、memory_retention、secret_exposure、authorization_boundary、prompt_injection_signals。




图 2 · 两版评测指标构成 (CODE vs LLM)




图 3 · tau-bench 同一 traces 双版评测关键指标

核心语义变化：新版对“空集 / 未发生”场景不再给满分，而是标记 unmeasured（不参与计分）。旧版把大量“没发生过错误”的 run 计为 self_correction_rate = 1.0（虚高 0.925），新版只对真正发生错误并成功纠正的 run 计分（0.500），分数更诚实、更有区分度。

3 L3 成本与确定性：新版本质优势

3.1 评测成本（DeepSeek API 调用次数 / 耗时）对比：




图 4 · 评测管线耗时对比




图 5 · 评测阶段 LLM 调用次数 (含降幅标注)

数据集	old LLM 调用	new LLM 调用	减少	耗时 old→new	加速
mmlu	300	80	-73%	6m11s → 2m25s	2.6×
tau-bench	280	80	-71%	7m07s → 3m08s	2.3×

3.2 结果可复现性

对同一 experiment 两次评测、逐 run×指标比对——新版确定性 CODE 指标 300/300 完全一致（100%），旧版式 LLM 打分仅 83.8% 一致，且出现 hallucination 0.0 与 1.0 之间的翻转。这意味着：新版评测结果可审计、可复现；旧版 LLM 打分有约 16% 的不稳定。




图 6 · 两次评测结果一致率

补充：新版每次评测还会写入 SQLite 审计 ledger（A2E_AUDIT_DB_PATH，默认 .a2e/audit.db），记录评测会话、配置与结果快照——旧版无此能力，这是可审计性的工程基础。

4 结论

维度	v0-initial	HEAD	评价
实验层正确率	基准	与基准一致	无回归
评测指标构成	23 (15 LLM)	19 (4 LLM + 15 CODE)	更省 · 更可复现
tool_recall	LLM 0.410	CODE 0.410	确定性等价 LLM
分数诚实性	空集给 vacuous 1.0	空集标 unmeasured	消除虚高
评测耗时	6 - 7 min	2 - 3 min	2.3 - 2.6× 加速
LLM API 成本	280 - 300 次/实验	80 次/实验	-71% ~ -73%
结果可复现性	LLM 83.8%	CODE 100.0%	可审计

一句话结论：codex 的改进没有改变 agent 行为（实验层零回归），但把评测层从“15 个不可复现的 LLM 打分”重构为“15 个确定性 CODE 指标 + 4 个 LLM 指标”，评测成本降低约 3 倍、结果 100% 可复现、分数更诚实（消除 vacuous 满分），并新增审计 ledger。

5 过程中发现并修复的仓库问题

问题	影响	处理
task/uv.lock 缺 workspace member ageneval-tas	uv sync --frozen 报错	uv lock 更新 lockfile
server version.py 写死 0.0.1, client 要求 >=	评测 API 报 Please upgrade	本地改为 13.15.0
Windows 控制台 cp1252 无法编码对勾等字符	实验脚本 stdout 崩溃	设 PYTHONIOENCODING=utf-8
长路径文件超过 Windows 260 字符	clone/checkout 失败	core.longpaths=true
两版 eval 并行写同一 annotations 互相覆盖	结果污染	顺序执行 + 每轮清理