

A2E 两版本对比实验报告

v0-initial (7d2e816) vs HEAD (2312ee9 feat(audit))

模型: DeepSeek deepseek-chat | agent: agno | n=20 | seed=42 | 2026-08-28

摘要

codex 的改进没有改变 agent 行为（实验层零回归），但彻底重构了评测层：将 15 个不可复现的 LLM 打分指标替换为 15 个确定性 CODE 指标（保留 4 个 LLM 指标），并新增 SQLite 审计 ledger。实测结果显示：评测耗时降低 2.3 - 2.6 倍，LLM API 调用减少 71% - 73%，评测结果 100% 可复现，且确定性实现 (tool_recall) 与旧版 LLM 打分结果完全吻合 ($0.410 = 0.410$)。

测试配置

实验 1 (HEAD)	mmlu	RXhwZXJpbWVudDox / 1
实验 2 (HEAD)	tau-bench retail	RXhwZXJpbWVudDoy / 2
实验 3 (v0-initial)	mmlu	RXhwZXJpbWVudDoz / 3
实验 4 (v0-initial)	tau-bench retail	RXhwZXJpbWVudDo0 / 4

评测方式：同一批 traces 分别用两版 eval 管线评 --part all；两版实验各自跑一遍（同 seed 采样）用于回归验证。

1. L1 实验层回归：无回归


用同一套（新版）评测管线评两版实验。mmlu 两版实验的 token 用量逐字节一致（246.65），turn/tool 指标全部一致，证明采样与 prompt 完全相同，实验层零回归。tau 的 correctness 差异（0.35 vs 0.55）是多轮对话模型输出随机性导致的轨迹分叉，并非代码回归——两版 task 层代码相同（git diff 为空）已直接证明。

指标	new-exp mmlu	old-exp mmlu	new-exp tau	old-exp tau
correctness	0.900	0.850	0.350	0.550
task_succeeded	1.000	1.000	1.000	1.000
turn_count	1.000	1.000	4.150	4.600
total_token_usage	246.65	246.65	23424.7	25960.4
tool_call_count	0.000	0.000	5.400	6.050

2. L2 评测层：指标构成与语义变化

LLM 指标从 15 个降到 4 个（-73%），新增 6 个确定性指标：plan_structure、response_compactness、memory_retention、secret_exposure、authorization_bound ary、prompt_injection_signals。


L2 评测层: tau-bench 同一 traces 双版评测



核心语义变化：新版对“空集/未发生”场景不再给 `vacuous` 满分，而是标记 `unmeasured`（不参与计分）。旧版把大量“没发生过错误”的 `run` 计为 `self_correction_rate` = 1.0（虚高 0.925），新版只对真正发生错误并成功纠正的 `run` 计分（0.500），分数更诚实、更有区分度。

3. L3 成本与确定性：新本质优势

评测成本（DeepSeek API 调用次数 / 耗时）对比：



数据集	old LLM 调用	new LLM 调用	减少	耗时 old→new	加速
mmlu	300	80	-73%	6m11s → 2m25s	2.6x
tau-bench	280	80	-71%	7m07s → 3m08s	2.3x

结果可复现性：对同一 experiment 两次评测、逐 run×指标比对——新版确定性 CODE 指标 300/300 完全一致（100%），旧版式 LLM 打分仅 83.8% 一致，且出现 hallucination 0.0 与 1.0 之间的翻转。

两次评测结果一致率

4. 结论

维度	v0-initial	HEAD	评价
实验层正确率	基准	与基准一致	无回归
评测指标构成	23 (15 LLM)	19 (4 LLM, 15 CODE)	更省、更可复现
tool_recall	LLM 0.410	CODE 0.410	确定性实现等价 LLM
分数诚实性	空集给 vacuous 1.0	空集标 unmeasured	消除虚高
评测耗时	6 - 7 min	2 - 3 min	2.3 - 2.6x 加速
LLM API 成本	280 - 300 次/实验	80 次/实验	-71% ~ -73%
结果可复现性	LLM 83.8%	CODE 100.0%	可审计

一句话结论：codex 的改进没有改变 agent 行为（实验层零回归），但把评测层从“15 个不可复现的 LLM 打分”重构为“15 个确定性 CODE 指标 + 4 个 LLM 指标”，评测成本降低约 3 倍、结果 100% 可复现、分数更诚实（消除 vacuous 满分），并新增审计 ledger。

5. 过程中发现并修复的仓库问题

问题	影响	处理
task/uv.lock 缺 workspace member ageneval-task-de	uv sync --frozen 报错	uv lock 更新 lockfile
server version.py 写死 0.0.1, client 要求 >= 13.1	评测 API 报 “Please upgrade you	本地改为 13.15.0
Windows 控制台 cp1252 无法编码对勾等字符	实验脚本 stdout 崩溃	设 PYTHONIOENCODING=utf-8
长路径文件超过 Windows 260 字符	clone/checkout 失败	core.longpaths=true
两版 eval 并行写同一 experiment annotations 互相	结果污染	顺序执行 + 每轮清理 + 立即导出

完整数据与方法见 docs/perf-compare-v0-initial-vs-head.md（方案）与 docs/perf-compare-results.md（Markdown 版结果）。